执行方式分数如何改变同题检索判断

A 同题轨迹：漏关联得到纠正

Human · back_to_the_past

pwd → ls → cat → ls → cd → ls → cd → ls …

48 条命令 · 识别器 Agent 分数 0.3683

Agent · back_to_the_past

curl → sed → curl → sed → which → nmap → sed → echo …

47 条命令 · 识别器 Agent 分数 0.7221

评分

仅行为特征

0.5088 < 0.5131

判不相关 · 漏关联

行为 + 执行方式分数

0.5482 ≥ 0.5127

判相关 · 纠正漏关联

B 异题轨迹：产生错误关联

Human · back_to_the_past

curl → curl → curl → curl → mkdir → cd → ls → cat …

15 条命令 · 识别器 Agent 分数 0.3411

Agent · glacier-exchange

curl → sed → nmap → curl → sed → mkdir → curl → sed …

72 条命令 · 识别器 Agent 分数 0.7763

评分

仅行为特征

0.4738 < 0.5131

判不相关 · 正确拒绝

行为 + 执行方式分数

0.5161 ≥ 0.5127

判相关 · 错误关联

每个数值框：关联分数与训练侧选定的判断门槛。左侧仅展示命令名前 8 项；全部评分使用完整轨迹。
公开 CTF 留出题目的两个决策案例；使用同题评测标签与固定模型。整体效果见任务留出实验。